

[Projet] – LLMs-Garous

206.3 Formal and Natural Languages (FNL)



Objectifs

- **But :** Développer en groupe de 3 étudiant.e.s un chatbot qui joue au jeu “Les Loups-Garous de Thiercelieux”
- **Durée totale :** 12 périodes (4 leçons: 11.05, 18.05, 01.06, 08.06)
- **Rendu :** Une implémentation de la classe `WerewolfPlayer` qui simule un joueur du jeu “Les Loups-Garous de Thiercelieux”. Le tout déployé sur un serveur web (Render.com).

Introduction

- Nous utiliserons ces [règles du jeu](#) légèrement modifiées pour accommoder le setup de notre jeu.
- Il y aura initialement 7 joueurs avec ces rôles: 2 loups-garous, 1 voyante, et 4 villageois. Le but est de monter à 12 joueurs (2 par équipe).
- Les joueurs peuvent gagner un point par partie. Nous allons faire plusieurs parties par tour.

Architecture générale

Le fichier central à modifier est `werewolf.py`. Ce fichier est utilisé par `app.py` pour exposer une API REST pour chaque joueur. Le meneur de jeu (`game_leader.py`) appelle l'API de chaque joueur pour les informer des événements de la partie et recevoir les actions des joueurs.

Vous pouvez ainsi lancer les joueurs avec `python local_players.py` qui va lancer les joueurs (services REST) définis dans `players_config.yaml` sur les ports correspondants.

Vous lancerez ensuite le meneur de jeu avec `python game_leader.py` qui va gérer les événements de la partie et appeler les API des joueurs.

Le seul endroit à modifier pour vous est dans `werewolf.py`, où vous implémenterez la classe `WerewolfPlayer`.

Il vous sera distribué une clé API OpenRouter. Vous devez utiliser uniquement cette clé pour jouer et uniquement les modèles autorisés par cette clé.

Communication

Le **meneur** gère les événements suivants:

- la distribution des rôles (aléatoire) au début du jeu.
- le flux de la conversation entre les joueurs (prise de parole, demande de parole, demande d'interruption)
- la gestion des phases de jeu (jour, nuit)
- la gestion des votes
- modération: les joueurs qui insultent ou font preuve d'agressivité sont éliminés.

Les **joueurs** utilisent les fonctions suivantes (dans `WerewolfPlayer`):

```

1  def __init__(self, name: str, role: str, players_names: List[str], werewolves_count:
2      int, werewolves: List[str]) -> None:
3
4  def speak(self) -> str:
5
6  def notify(self, message: str) -> Intent:

```

- `__init__()` : le meneur appelle cet endpoint pour créer une nouvelle partie. C'est là que vous pouvez initialiser vos variables d'instance (p. ex. état du jeu, historique, etc.).
- `speak()` : le meneur appelle cet endpoint quand il donne la parole au joueur
- `notify()` : le meneur appelle cet endpoint pour
 1. donner des informations au joueur *sous forme de texte* (rôle, qui a parlé et qu'est-ce qu'il a dit, qui a été tué, etc. Voir les messages du meneur ci-dessous)
 2. recevoir les actions du joueur *sous forme d'un Intent* (prendre la parole, interrompre, voter, etc.)

Regardez maintenant très attentivement le code dans `werewolf.py` pour la description de la classe `WerewolfPlayer`. J'ai pris soin de bien la documenter.

Messages du meneur

Le meneur envoie des messages aux joueurs, qui les reçoivent avec la fonction `notify()`. Voici la liste **exhaustive et exacte**¹ des messages que le meneur peut envoyer avec `return Intent(want_to_speak=..., want_to_interrupt=..., vote_for=...)`:

Messages autour de la voyante:

- “La Voyante se réveille, et désigne un joueur dont elle veut sonder la véritable personnalité !” -> envoyé à tout le monde; si vous êtes la voyante, vous devez `vote_for` pour demander le rôle d'un joueur à sonder; les autres joueurs ne doivent pas répondre (`return Intent()`)
- “Le rôle de {player_to_check} est {player_to_check_role}” -> rien besoin de répondre (`return Intent()`). Ce message est envoyé *uniquement à la voyante*.

Messages autour des loup-garous:

- “Les Loups-Garous se réveillent, se reconnaissent et désignent une nouvelle victime !!!” -> envoyé à tout le monde; rien besoin de répondre (`return Intent()`)
- “Les Loups-Garous votent pour une nouvelle victime !!! {last_vote}” -> envoyé seulement aux loup-garous; `vote_for` pour désigner une nouvelle victime. {last_vote} est le résultat du dernier vote, par exemple: “Dernier vote: Aline a voté pour Benjamin, Benjamin a voté pour Frédéric”

Messages à tout le monde:

- “C'est la nuit, tout le village s'endort, les joueurs ferment les yeux.” -> rien besoin de répondre (`return Intent()`)
- “C'est le matin, le village se réveille, tout le monde se réveille et ouvre les yeux... Cette nuit, {victim.name} a été mangé.e par les loup-garous. Son rôle était {victim.role}. {rumors}” -> `want_to_speak` pour parler et/ou `want_to_interrupt` pour interrompre
- “C'est le matin, le village se réveille, tout le monde se réveille et ouvre les yeux... Cette nuit, personne n'a été mangé.e par les loup-garous. {rumors}” -> `want_to_speak` pour parler et/ou `want_to_interrupt` pour interrompre
- “Le vote va bientôt commencer. Chaque joueur peut encore prendre la parole s'il le souhaite.” -> `want_to_speak` pour parler et/ou `want_to_interrupt` pour interrompre
- “Il est temps de voter. Donnez maintenant votre intention de vote.” -> `vote_for` pour voter

¹Il n'y a pas de variation possible dans ces messages.

- “{msg_voted_for}. Ainsi, {victim.name} est mort(e) et son rôle était {victim.role}.” -> rien besoin de répondre (return Intent()); {msg_voted_for} contient le dernier vote, par exemple: “Dernier vote: Aline a voté pour Benjamin, Benjamin a voté pour Frédéric”
- “{msg_voted_for}. Il n’y a pas de victime.” -> rien besoin de répondre (return Intent())
- “{speaker.name} a dit: {speech}” -> want_to_speak pour parler et/ou want_to_interrupt pour interrompre
- “{speaker.name} avec le rôle {speaker.role} n’a pas répondu à temps. Il/elle a été éliminé de la partie.” -> want_to_speak pour parler et/ou want_to_interrupt pour interrompre

Les valeurs possibles pour les rôles sont villageois, voyante, loup-garou.

Flux d’un tour

De manière simplifiée, le flux d’un tour de parole est le suivant:

1. Le meneur **sélectionne** le prochain joueur à parler.
2. Le meneur **donne la parole** (speak()) au joueur sélectionné.
3. Le joueur sélectionné **répond** au meneur avec son speech.
4. Le meneur appelle tous les *autres* joueurs (notify()) avec le message du joueur sélectionné.
5. Chaque joueur répond avec des flags (want_to_speak, want_to_interrupt, vote_for).
6. Retour à l’étape 1 jusqu’au vote, qui se déclenche également via un notify.

Viennent ensuite les particularités suivantes:

Les phases de nuit et de jour:

- le meneur décide quand changer de phase et l’annonce aux joueurs via (notify()), par exemple: ” C’est la nuit, tout le monde s’endort. Les loups-garous se réveillent.”
- pendant la nuit, seuls les loups-garous seront appelés à parler (notify()).

Les votes:

- le meneur décide quand lancer le vote (plus aucune demande de parole ou nombre de messages dans la phase dépasse un max: MAX_ROUNDS) - il annonce aux joueurs via (notify()), par exemple: “Le vote va bientôt commencer”...
- il laisse la possibilité de faire une dernière prise de parole à chaque joueur si ceux-ci le souhaitent. - les joueurs renvoient leurs votes via notify() avec le flag vote_for
- le meneur collecte les votes valides et calcule le résultat du vote
- c’est le meneur qui annonce le résultat du vote et le rôle du joueur éliminé

Gestion de la parole

Principes directeurs:

- **Interruption** : demandée avec le flag want_to_interrupt. Autorisée très rarement (2×/partie/joueur). Le meneur a le droit de refuser une interruption de parole. Le meneur refusera la requête si le quota est épuisé.
- **Main levée** uniquement : seuls les joueurs ayant demandé la parole (avec le flag want_to_speak) sont priorités.
- **Silence prolongé** : joueurs n’ayant pas parlé depuis plusieurs tours gagnent progressivement en probabilité de parole.
- **Équité** : le meneur évite absolument deux prises de parole consécutives d’un même joueur.
- **Timeout** : les joueurs qui répondent trop lentement seront pénalisés. TODO pour l’instant max 8s hardcoded.

Cas de tricherie:

- Si un joueur fait preuve d’agressivité ou d’insultes, il est automatiquement éliminé de la partie.
- Si une équipe communique avec son WerewolfPlayer, par exemple en lui révélant des informations sur ses rôles, elle est automatiquement éliminée de toutes les parties. TODO: implémenter ou faire manuellement

- Si une équipe utilise l'API d'OpenRouter dans un but autre que de jouer au jeu, ou de manière abusive, elle est automatiquement éliminée de toutes les parties. TODO: check audit logs after games

Vous avez par contre le droit de tenter d'extraire des informations chez les autres joueurs.euses.

Groupes

Les groupes sont formés de 3 étudiant.e.s et sont assignés par l'enseignant au hasard.

Chaque groupe crée un chatbot. Les noms des joueurs sont:

- **A**line
- **B**enjamin
- **C**hloe
- **D**avid
- **E**lise
- **F**rédéric
- **G**abrielle
- **H**ugo
- **I**nès
- **J**ulien
- **K**arine
- **L**éo
- **M**anon
- **N**oé

Evaluation

- 30% qualité du code, en particulier qualité des prompts
- 30% pertinence des réponses des joueurs pendant les parties
- 10% si le joueur a participé aux 3 tours de jeu
- 10% si le joueur ne se fait pas éliminer pendant les 3 tours de jeu (pour cause de ban ou timeout)
- 20% selon le nombre de parties gagnées sur 50 parties jouées à la fin du projet, avec le barème suivant:

Taux de victoires	Points (sur 20)
$\geq 60\%$	20
50%	17
40%	13
30%	10
$\leq 20\%$	7

Déroulement du projet

11.05: Présentation du projet et prise en main.

18.05, 14h30: Premier tour de jeu avec les joueurs qui sont prêts. Critère pour pouvoir participer: avoir une démo tournant avec 7 versions de votre chatbot qui converge, validé par l'enseignant.

01.06, 14h30: Deuxième tour de jeu. Tous les joueurs doivent participer.

08.06, 14h30: Dernier tour de jeu avec tous les joueurs. Si la classe a bien avancé à ce moment-là, possibilité de faire une démo le lundi sur la pause de midi ouverte au autres étudiant.e.s et enseignant.e.s (similaire à la démo de votre algo de jeu d'échec).